



تمرین تئوری دوم درس تحلیل تصاویر پزشکی

علیرضا دهقانپور فراشاه

۹۸۱۰۱۵۵۵

سوال یک

(آ)

تفاوت این دو روش این است که در روش 1T مدت زمانی که طول می کشد تا اتم ها با میدان خارجی همسو شوند در نظر گرفته می شود ولی در روش 2T مدت زمانی که طول می کشد اتم ها بعد از قطع شدن موج رادیویی دوباره نامنظم شوند اندازه گیری می شود. تفاوت این دو روش در رنگ برخی نواحی مشخص نمایان می شود به عنوان مثال در روش 2T سلول های خاکستری مغز نسبت به سلول های سفید روشن تر دیده می شوند ولی در 1T کاملاً برعکس است.

(ب)

$$HU = \frac{\mu - \mu_{water}}{\mu_{water}} = 1678$$

(ج)

مشکل آن Quantum Efficiency پایین آن است که نزدیک ۲ درصد است و با قرار دادن لایه تشدید کننده فلورسنت از جنس فسفر این مقدار به ۲۵ درصد می رسد.

(د)

در این روش روی نتیجه backprojection به علت اینکه فرکانس های پایین تر بیشتر سمپل می شوند یک فیلتر high pass زده می شود. علت این پدیده Fourier Slice theorem است و این کار باعث sharp شدن تصویر می شود. بدون اعمال این فیلتر این روش مشکل blur شدن تصویر را دارد. مزیت: اصلی ترین مزیت این روش حل معادلات به صورت آنی است که سبب سرعت محاسباتی بالا می شود. معایب: اگر محیط noisy باشد آنگاه در تصویر نهایی به علت فیلتر high pass دارای artifact خواهیم بود. همچنین نیاز است uniform angular sampling داشته باشیم که البته این مورد در مقاله های اخیر مورد سوال قرار گرفته است. روش های iterative به علت بهبود سرعت کامپیوترها جایگزین روش قبلی شده اند که مشکل نویز و شرایط ایده آل را ندارند. این دسته از روش ها sinogram تولید می کنند و با در نظر گرفتن یک نقطه در معادلات میرایی آن نقطه خاص را بدست می آورند.

<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4323100/>

<https://pubmed.ncbi.nlm.nih.gov/23587902/>

<https://radiopaedia.org/articles/iterative-reconstruction-ct>

سوال دو

(آ)

هر DICOM message یک جریانی از data element ها است که از ۴ بخش data tag و value length و value field و value representation است.

یک data element یا attribute در DICOM از دو بخش tag و VR تشکیل شده است.

- این تگ که عموماً به فرمت (XXXX,XXXX) به صورت اعداد هگزادسیمال نمایش داده می شود که نمایانگر Group Number و Element Number است.
- Value Representation یا VR که datatype و فرمت attribute value را مشخص می کند.
- Value Length که تعداد بایت value field را مشخص می کند.
- Value Field که مقدار یا همان value این دیتا المنت است.

(ب)

Rescale intercept و rescale slope تگ های DICOM هستند که تبدیل خطی از پیکسل ها در نمایش ذخیره شده روی دیسک به نمایش آنها در حافظه را مشخص می کنند.

$$U = m \cdot SV + b$$

در رابطه بالا m همان rescale slope و b همان rescale intercept است و SV مقدار ذخیره شده در حافظه و U همان مقدار در واحد خروجی است.

(ج)

به طور کلی شش حالت یا type دارد

1. **Type 1 Required Data Elements:** از فیلدهای اجباری می شود و باید وجود داشته باشد و value field باید مقدار معتبر داشته باشد و طول value field نباید صفر باشد و نبودن مقدار معتبر در Value نقض پروتکل استاندارد DICOM است.
 2. **Type 1C Conditional Data Elements:** تحت شرایط مشخصی باید این فیلد وجود داشته باشد. تمامی نکات ذکر شده برای تایپ قبلی برای این مورد نیز قابل ذکر است.
 3. **Type 2 Required Data Elements:** از فیلدهای اجباری است ولی با این تفاوت که مقدار آن می تواند نامشخص باشد و در این صورت Value Length باید صفر باشد
 4. **Type 2C Conditional Data Elements:** تحت شرایط مشخصی باید این فیلد وجود داشته باشد و بقیه شرایطش مانند بالا است.
 5. **Type 3 Optional Data Elements:** این حالت اختیاری است و نبود آن نقض پروتکل نیست. می تواند با طول صفر بیاید ولی به معنای نبود آن است.
 6. **Data Element Types Within A Sequence:** وقتی دنباله داشته باشیم تایپ Sequence Attribute مشخص کننده اجباری یا اختیاری بودن آن فیلد است و Attribute Discription نشان دهنده تعداد اعضای دنباله و نحوه قرارگیری آنها است.
- Anonymize در واقع حذف کردن اطلاعات شخصی افراد از دادگان است زیرا در این فایل ها اطلاعاتی چون سن تحصیلات و غیره آمده است و بایستی اسامی افراد حذف شود. توجه

https://dicom.nema.org/medical/dicom/current/output/chtml/part05/sect_7.4.html

سؤال ۳

$$I_{out} = \int_0^{\infty} G(E) e^{-\int_{min}^{x_{out}} \mu(x) dx} dE \quad *$$

$$= \int_{10}^{20} G(E) e^{-\left(\frac{3}{r} - \frac{1}{r_0} E\right)} dE + \int_{20}^{50} G(E) e^{-\left(\frac{1}{r_0} E + \frac{2.9}{r}\right)} dE$$

$$+ \int_{50}^{70} G(E) e^{-\frac{1}{r_0} E} dE$$

توجه کنید $G(E)$ فقط در پی
۱۵ MeV تا ۵۵ MeV مقدار دارد و 10^{-4} است بنابراین:

$$10^{-4} \left(\int_{10}^{20} e^{-\frac{3}{r} + \frac{1}{r_0} E} dE + \int_{20}^{50} e^{\frac{1}{r_0} E - \frac{2.9}{r}} dE + \int_{50}^{70} e^{-\frac{1}{r_0} E} dE \right) =$$

$$= 10^{-4} (2.24 + 18.32 + 3.17) = 0.00243$$

$$I_{in} = \int_{10}^{50} G(E) dE = 40 \times 10^{-4} = 0.04$$

$$\frac{I_{in}}{I_{out}} = \frac{40}{0.00243} = 16461$$

* طول جسم ۱ cm است و چون ثابت است در طول جسم می شود $M \times 1 \text{ cm}$ و چون

در هر M طبق مقدار $\frac{1}{cm}$ است سلاسه می شود.

سوال چهار

روش pre-processing گفته شده در مقاله به این صورت است که ابتدا محدوده مقادیر HU را بدست می‌آورد. سپس پارامتری به نام P را به صورت زیر محاسبه می‌کند.

$$HU_{range} = HU_{max} - HU_{min}$$

$$P = HU_{pixelValue} / HU_{range}$$

حال اگر مقدار P کمتر از ۰.۵ باشد مقادیر هر یک از کانال‌های رنگی را به صورت زیر محاسبه می‌کند:

$$Red = (1-2p) * 255$$

$$Green = 255 * 2 * p$$

$$Blue = 0$$

و اگر مقدار P بیشتر از 0.5 باشد:

$$Red = 0$$

$$Green = 255 * (1 - (p - 0.5) * 2)$$

$$Blue = 255 * (p - 0.5) * 2$$

سپس با محاسبه این مقادیر حال به segmentation می‌پردازد که از روش‌های ساده به مانند thresholding استفاده می‌کند که به این صورت که اختلاف رنگ در سه کانال به توان دو و همچنین فاصله دو ناحیه در تشخیص ناحیه tumor در نظر می‌گیرد. این روش زمانی که بخواهیم یک ناحیه مشخص که محدوده HU مشخصی داشته باشد می‌تواند کمک کننده باشد زیرا می‌توان این ناحیه محدود را به صورت خطی به یک ناحیه گسترده‌تر در رنگ‌های سبز، قرمز و آبی برود.

روش‌های دیگری که امروزه استفاده می‌شوند می‌توان از Histogram Matching نام برد. این روش به این صورت است که مثلاً یک مدل segmentation بر روی یک سری داده با توزیع رنگ خاصی که ممکن از setup خاص یک آزمایش آمده باشد یادگرفته می‌شود. برای استفاده از این مدل برای دادگان آزمایش‌های دیگر که setup متفاوتی دارند از این preprocessing استفاده می‌شود که سعی می‌کند توزیع عکس ورودی را به توزیع عکس‌های زمان یادگیری نزدیک کند.

همچنین روش‌های دیگری نیز هستند که توزیع رنگ یک تصویر را سعی می‌کنند نرمال کنند که این دو روش عملاً یک چیز هستند با این تفاوت که توزیع دوم در این حالت توزیع یونیفرم است. این کار باعث sharp شدن و ایجاد contrast در تصویر می‌شود. از نظر تئوری این کار با اعمال یک تابع بر روی توزیع قابل انجام است که در کلاس نیز مطرح شد و این تابع همان CDF توزیع اولیه است. اگر متغیر تصادفی X با تابع توزیع تجمعی F داشته باشیم آنگاه متغیر تصادفی Y که به صورت $Y = F(X)$ تعریف می‌شود دارای توزیع یونیفرم خواهد بود. اثبات آن در زیر آمده است.

$$\begin{aligned} F_Y(y) &= P(Y \leq y) = \\ &= P(F_X(X) \leq y) \\ &= P(X \leq F_X^{-1}(y)) \\ &= F_X(F_X^{-1}(y)) \\ &= y \end{aligned}$$

برای انجام این کار در تصاویر با نمونه برداری می‌توان تخمین از CDF توزیع عکس داشت.

این روش برای عکس‌های grayscale کارا و کارآمد است و همچنین سریع است و باعث ایجاد artifact نمی‌شود ولی برای عکس‌های رنگی خیلی قابل انجام نیست زیرا هر کانال رنگی به توزیع دارد.

سوال پنج

در این مقاله روش‌های متعددی برای preprocessing و post processing مطرح شده‌است که برای هر یک از دو موضوع چند روش را شرح می‌دهیم.

Preprocessing

یکی از متدهای پیش‌پردازش گفته شده در مقاله برای artifact detection استفاده از روش‌های boosting مانند AdaBoost است. مقاله‌ی این روش Automated Training Data Generation for Microscopy Focus Classification است که مورد بررسی قرار گرفت. این روش باعث بهبود دقت در این تسک شده‌است. در این روش یک classifier آموزش داده می‌شود که به نواحی in-focus و out-of-focus تقسیم می‌کند. در این مقاله برای بدست آوردن دسته‌بند AdaBoost به عنوان weak learner از linear discriminant analysis استفاده می‌کند و این دسته بند هر ناحیه را به صورت باینری دسته بندی می‌کند.

یک روش دیگر که در تسک patch selection استفاده می‌شود استفاده از مدل Alexnet که از تعدادی لایه convolution تشکیل شده‌است و نواحی مورد نیاز که nuclear هستند را جدا می‌کند. این کار بر روی یک دیتاست که از تصاویر سرطان سینه تشکیل شده‌اند تست شده و نتایج بهبود یافته بود.

روش‌های convolution based نیز در مقاله مطرح شده بودند که با اعمال فیلترهای مختلف اجزای مختلف عکس را enhance می‌کنند.

Post-processing

یکی از متدهای مطرح شده CNN + graph partitioning model است که به این صورت است که بعد از چند لایه CNN به تعدادی feature می‌رسد و بعد از آن با استفاده از graph partitioning مدل عملکرد و سرعت segmentation را بهبود می‌بخشد. متد graph partitioning برای بدست آوردن بخش‌های parallel محاسبات است. دو پایلین دیگر نیز در مقاله اشاره شده بود که یکی از آن‌ها در ادامه توضیح داده می‌شود. ایده اصلی در هر دو استفاده از روش‌های کلاسیک بعد از خروجی شبکه CNN است. مثلاً در دومین پایلین بعد از segmentation از connected component analysis استفاده می‌کند و مثلاً object های کوچک را حذف می‌کند.

در خیلی از روش‌ها نیز در انتهای CNN یا UNET از thresholding استفاده شده بود. Thresholding یک متد ساده است که با تعیین یک threshold مثلاً بر روی رنگ پیکسل است و می‌توان برای تعیین threshold نیز از الگوریتم‌های مختلفی استفاده کرد.